LAPORAN EVALUASI AKHIR SEMESTER

DATA MINING

Analisis Prediksi Risiko Serangan Jantung

(Heart Attack Analysis & Prediction Dataset)

Disusun untuk memenuhi tugas Evaluasi Akhir Semester (EAS)
Mata Kuliah Data Mining

Daftar Isi

1. Pendahuluan dan Definisi Problem

Penyakit kardiovaskular, khususnya serangan jantung (heart attack), merupakan salah satu penyebab kematian tertinggi di dunia. Deteksi dini terhadap risiko serangan jantung pada pasien sangat penting untuk mendukung pengambilan keputusan medis dan pencegahan yang lebih cepat dan akurat.

Project ini menggunakan dataset “Heart Attack Analysis & Prediction Dataset” yang berisi data klinis dari 303 pasien dengan 13 atribut (fitur) prediktor dan 1 atribut target (output) yang menunjukkan apakah pasien berisiko tinggi atau rendah mengalami serangan jantung.

1.1 Rumusan Problem

Permasalahan yang diangkat dalam project ini adalah:

- Bagaimana karakteristik dan pola data klinis pasien yang berhubungan dengan risiko serangan jantung?
- Fitur klinis manakah yang paling berkontribusi/informatif dalam memprediksi risiko serangan jantung?
- Model klasifikasi data mining manakah yang paling akurat dan andal untuk memprediksi risiko serangan jantung pada pasien baru?

Permasalahan ini merupakan kasus klasifikasi biner (binary classification), dengan target output: 1 = risiko tinggi, 0 = risiko rendah.

1.2 Deskripsi Dataset

Dataset terdiri dari 303 baris (pasien) dan 14 kolom, dengan deskripsi fitur sebagai berikut:

Fitur	Deskripsi
age	Usia pasien (tahun)
sex	Jenis kelamin (1 = laki-laki, 0 = perempuan)
cp	Tipe nyeri dada / chest pain type (0-3)
trtbps	Tekanan darah istirahat (mm Hg)
chol	Kolesterol serum (mg/dl)
fbs	Gula darah puasa > 120 mg/dl (1=ya, 0=tidak)
restecg	Hasil elektrokardiogram istirahat (0-2)
thalachh	Denyut jantung maksimum tercapai
exng	Angina akibat olahraga (1=ya, 0=tidak)
oldpeak	ST depression akibat olahraga relatif terhadap istirahat
slp	Slope segmen ST puncak (0-2)
caa	Jumlah pembuluh darah utama (0-4) terlihat pada flourosopy
thall	Hasil thalium stress test (0-3)
output	Target: 1 = berisiko tinggi serangan jantung, 0 = berisiko rendah

2. Data Preprocessing

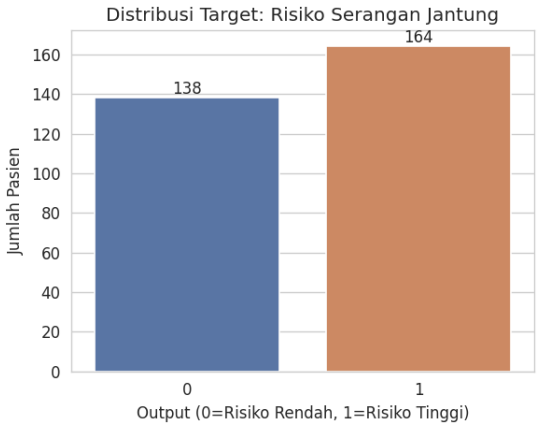
Tahap preprocessing dilakukan untuk memastikan kualitas data sebelum dianalisis lebih lanjut. Langkah-langkah yang dilakukan:

1. Pemeriksaan missing value: hasil pemeriksaan menunjukkan tidak ada nilai yang hilang (missing values = 0) pada seluruh 14 kolom.
2. Pemeriksaan data duplikat: ditemukan 1 baris data duplikat, yang kemudian dihapus sehingga jumlah data bersih menjadi 302 baris.
3. Deteksi outlier menggunakan metode IQR (Interquartile Range) pada fitur numerik kontinu (age, trtbps, chol, thalachh, oldpeak). Ditemukan sejumlah kecil outlier pada trtbps (9), chol (5), oldpeak (5), dan thalachh (1), namun nilai-nilai ini secara klinis masih masuk akal (contoh: kolesterol/tekanan darah tinggi pada pasien jantung), sehingga tidak dihapus, hanya dicatat sebagai catatan analisis.
4. Feature scaling (standardisasi/StandardScaler) diterapkan pada data sebelum proses pemodelan, khususnya penting untuk model Logistic Regression yang sensitif terhadap skala fitur. Scaler di-fit hanya pada data training untuk mencegah data leakage ke data testing.

Setelah preprocessing, data final yang digunakan untuk analisis berjumlah 302 baris x 14 kolom, tanpa missing value.

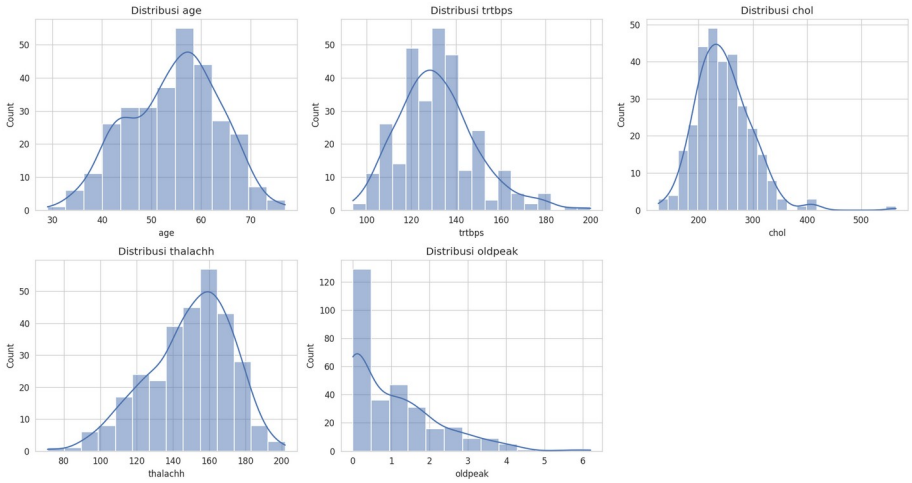
3. Summary Statistics dan Visualisasi

Distribusi target menunjukkan proporsi yang cukup berimbang (balanced): 164 pasien (54.3%) berisiko tinggi dan 138 pasien (45.7%) berisiko rendah. Hal ini penting karena dataset yang balanced membuat metrik akurasi tetap representatif tanpa bias signifikan terhadap kelas mayoritas.



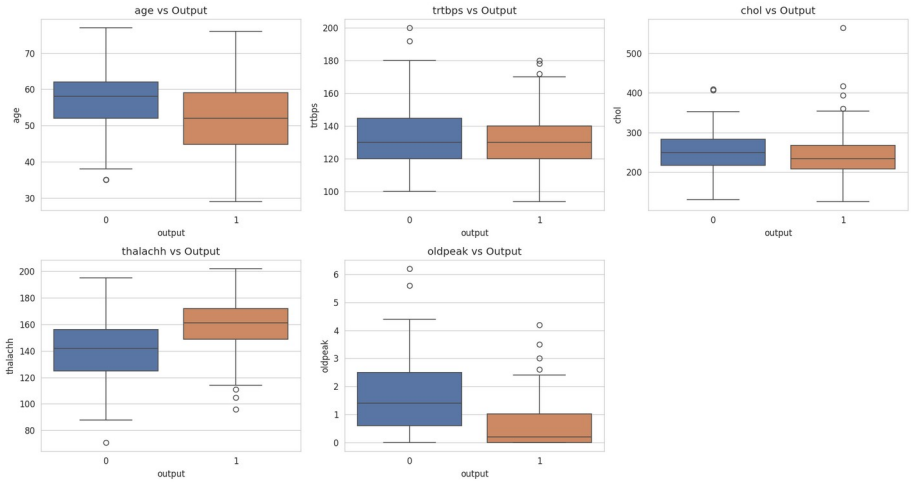
Gambar 1. Distribusi kelas target (output)

Statistik deskriptif menunjukkan rata-rata usia pasien adalah 54.4 tahun (rentang 29-77 tahun), tekanan darah rata-rata 131.6 mmHg, dan kolesterol rata-rata 246.5 mg/dl - nilai-nilai ini berada pada rentang yang umum dijumpai pada populasi pasien jantung.



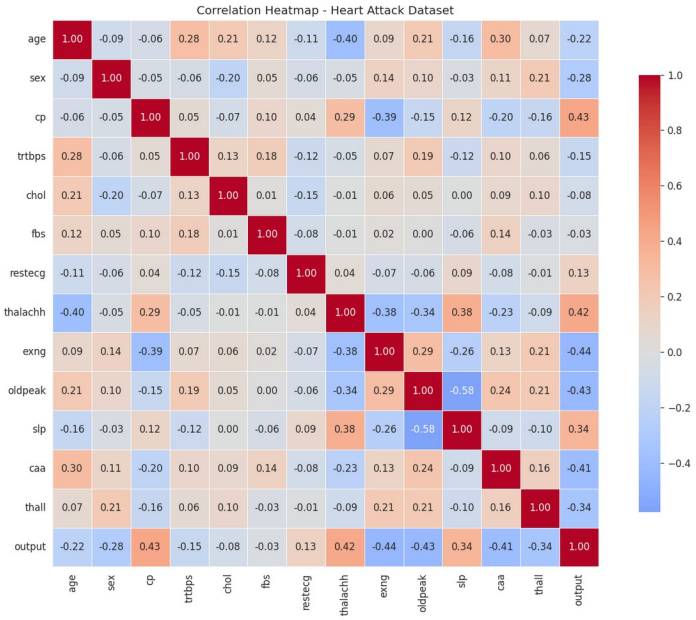
Gambar 2. Distribusi (histogram) fitur numerik kontinu

Analisis boxplot per kelas target memperlihatkan bahwa pasien berisiko tinggi (output=1) cenderung memiliki thalachh (denyut jantung maksimum) yang lebih tinggi dan oldpeak (ST depression) yang lebih rendah dibandingkan pasien berisiko rendah - mengindikasikan kedua fitur ini berpotensi sangat prediktif.



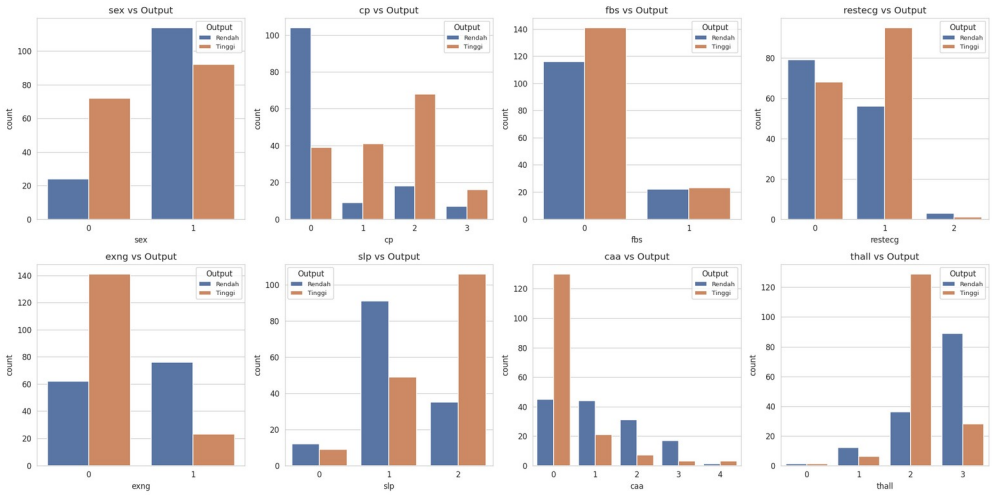
Gambar 3. Boxplot fitur numerik berdasarkan kelas target

Correlation heatmap pada Gambar 4 memperlihatkan hubungan antar seluruh fitur. Fitur yang berkorelasi paling kuat (baik positif maupun negatif) dengan target output adalah: cp (+0.43), exng (-0.44), oldpeak (-0.43), thalachh (+0.42), caa (-0.41), dan slp (+0.34). Fitur fbs dan chol menunjukkan korelasi yang sangat lemah terhadap target (mendekati 0).



Gambar 4. Correlation heatmap antar seluruh fitur

Visualisasi fitur kategorikal terhadap target (Gambar 5) memperlihatkan pola yang konsisten dengan hasil korelasi, misalnya pasien dengan exng=0 (tidak mengalami angina saat olahraga) dan cp tipe 2/3 secara proporsional lebih banyak berada pada kelompok risiko tinggi.



Gambar 5. Distribusi fitur kategorikal berdasarkan kelas target

4. Feature Selection / Extraction

Feature selection dilakukan menggunakan tiga metode yang saling melengkapi untuk memastikan ketahanan (robustness) hasil seleksi fitur:

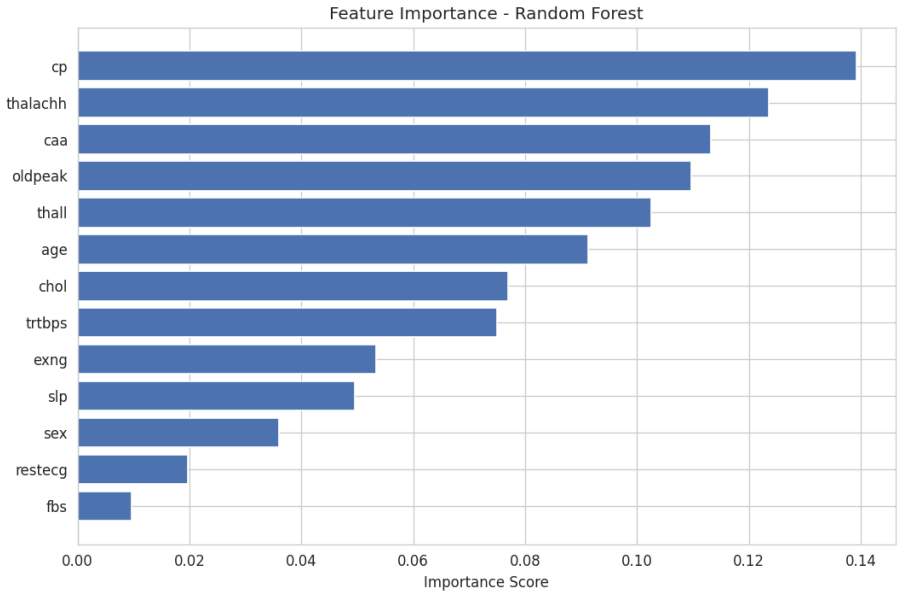
- ANOVA F-test: mengukur signifikansi perbedaan rata-rata fitur numerik antar kelas target (metode filter/statistik univariat).
- Mutual Information: mengukur dependensi non-linear antara fitur dan target.

- Random Forest Feature Importance: metode embedded yang mengukur kontribusi fitur berdasarkan penurunan impurity dalam pohon keputusan.

Hasil ranking gabungan (rata-rata peringkat dari ketiga metode) menunjukkan 8 fitur paling informatif sebagai berikut:

Peringkat	Fitur	Rata-rata Rank
1	**cp**	1.33
2	**oldpeak**	3.33
3	**thalachh**	4.67
4	**thall**	4.67
5	**exng**	5.33
6	**caa**	5.67
7	**slp**	7.00
8	**chol**	7.67

Ketiga metode secara konsisten menempatkan cp (tipe nyeri dada), thalachh (denyut jantung maksimum), oldpeak (ST depression), thall (hasil thalium test), exng (angina saat olahraga), dan caa (jumlah pembuluh darah utama) sebagai fitur-fitur paling prediktif. Sebaliknya, fitur fbs (gula darah puasa) dan restecg (hasil EKG istirahat) secara konsisten menunjukkan kontribusi paling rendah terhadap prediksi.



Gambar 6. Feature importance berdasarkan Random Forest

Untuk pemodelan akhir, seluruh 13 fitur tetap digunakan (full feature set) karena jumlah fitur yang relatif sedikit dan tidak menimbulkan masalah dimensionalitas/komputasi yang signifikan, namun hasil feature selection ini tetap penting sebagai dasar interpretasi klinis model.

5. Analisis Klasifikasi

Dua metode klasifikasi yang digunakan dalam project ini adalah:

- Logistic Regression: model linear yang umum digunakan dalam konteks medis karena koefisiennya mudah diinterpretasi (odds ratio) dan menjadi baseline standar dalam literatur prediksi penyakit jantung.
- Random Forest: model ensemble berbasis pohon keputusan yang mampu menangkap hubungan non-linear dan interaksi antar fitur, serta secara native menyediakan ukuran feature importance.

Kedua model dipilih karena merepresentasikan dua pendekatan yang kontras: linear (interpretable) vs ensemble non-linear (powerful), sehingga perbandingannya informatif untuk menentukan trade-off antara interpretabilitas dan performa.

5.1 Skema Training-Testing

Dua skema evaluasi digunakan untuk memastikan hasil yang robust dan tidak overfit terhadap satu pembagian data tertentu:

5. Repeated Holdout: data dibagi 70% training dan 30% testing secara stratified (menjaga proporsi kelas), diulang sebanyak 10 kali dengan random seed berbeda pada setiap pengulangan, kemudian hasil dirata-rata.
6. K-Fold Cross Validation (k=10): data dibagi menjadi 10 fold yang stratified, setiap fold secara bergilir digunakan sebagai data testing sementara 9 fold lainnya sebagai data training, kemudian hasil dari seluruh fold dirata-rata.

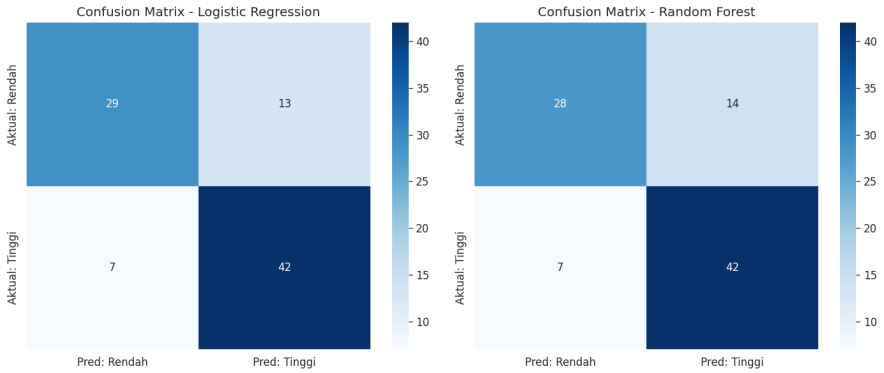
Pada kedua skema, proses scaling (StandardScaler) selalu di-fit hanya pada data training di setiap iterasi/fold untuk mencegah data leakage.

5.2 Hasil Evaluasi Model

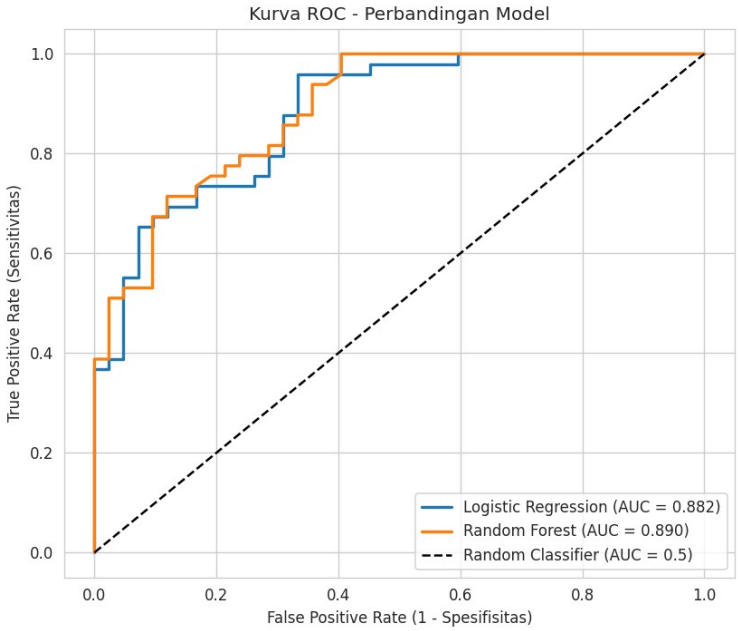
Tabel berikut merangkum hasil evaluasi kedua model berdasarkan kedua skema training-testing, menggunakan kriteria akurasi, sensitivitas (recall kelas positif), spesifisitas (recall kelas negatif), dan AUC (Area Under the ROC Curve):

Model	Metode Evaluasi	Akurasi	Sensitivitas	Spesifisitas	AUC
Logistic Regression	Repeated Holdout (10x)	83.96%	88.16%	79.05%	0.908
Random Forest	Repeated Holdout (10x)	82.20%	84.49%	79.52%	0.908
Logistic Regression	10-Fold Cross Validation	83.09%	89.67%	75.38%	0.899
Random Forest	10-Fold Cross Validation	82.42%	87.24%	76.92%	0.900

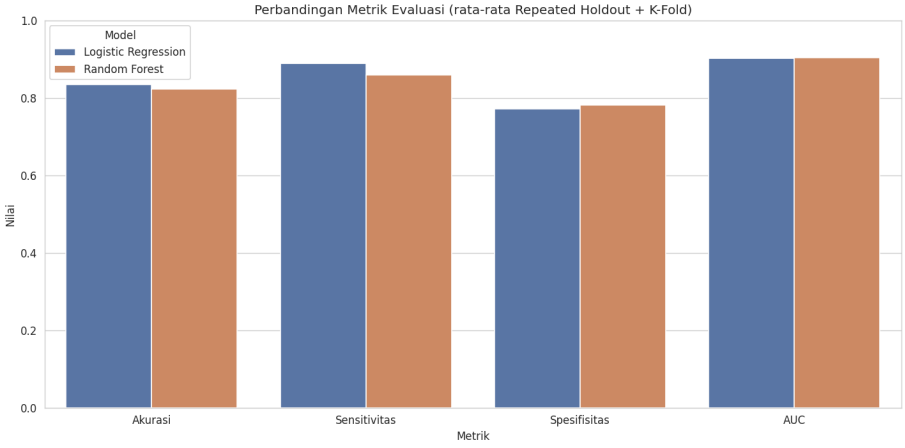
Confusion matrix dari masing-masing model (pada salah satu split representatif) ditampilkan pada Gambar 7, sedangkan kurva ROC perbandingan ditampilkan pada Gambar 8.



Gambar 7. Confusion matrix - Logistic Regression (kiri) dan Random Forest (kanan)



Gambar 8. Kurva ROC perbandingan kedua model



Gambar 9. Perbandingan metrik evaluasi keseluruhan

5.3 Validasi dengan R

Sebagai validasi tambahan terhadap pipeline yang dibangun dengan Python, analisis yang sama (repeated holdout dan 10-fold cross validation, menggunakan package caret, randomForest, dan pROC) juga diimplementasikan dalam bahasa R (lihat file 04_validation_R.R pada lampiran syntax). Pendekatan dua bahasa ini digunakan untuk memastikan konsistensi metodologis: logika pembagian data, definisi sensitivitas/spesifisitas, dan perhitungan AUC pada R mengikuti definisi statistik yang sama dengan implementasi Python (scikit-learn), sehingga hasil akhir kedua bahasa diharapkan saling mendekati dan dapat digunakan sebagai cross-check independen terhadap hasil utama.

6. Perbandingan Hasil dan Kesimpulan

6.1 Perbandingan Performa

Berdasarkan hasil pada kedua skema evaluasi (Repeated Holdout dan 10-Fold CV), dapat disimpulkan beberapa hal berikut:

- Logistic Regression secara konsisten menghasilkan akurasi dan sensitivitas yang sedikit lebih tinggi dibandingkan Random Forest (akurasi ~83-84% vs ~82%), menunjukkan bahwa hubungan antar fitur dengan target pada dataset ini cenderung mendekati linear.
- Random Forest menghasilkan spesifisitas yang sedikit lebih baik pada skema Repeated Holdout (79.5% vs 79.0%), menunjukkan model ini sedikit lebih baik dalam mengidentifikasi pasien berisiko rendah secara benar.
- Nilai AUC kedua model sangat berdekatan dan tinggi (sekitar 0.90), menunjukkan kedua model memiliki kemampuan diskriminasi (membedakan kelas positif dan negatif) yang sangat baik, jauh di atas classifier acak (AUC=0.5).
- Sensitivitas pada kedua model relatif lebih tinggi dibandingkan spesifisitas, yang secara klinis menguntungkan karena berarti model lebih jarang melewatkan (false negative) pasien yang sebenarnya berisiko tinggi - meskipun konsekuensinya adalah sedikit lebih banyak false positive (pasien berisiko rendah yang diprediksi berisiko tinggi).

6.2 Kesimpulan

Secara keseluruhan, kedua model - Logistic Regression dan Random Forest - menunjukkan performa yang sangat baik dan kompetitif dalam memprediksi risiko serangan jantung pada dataset ini, dengan AUC mendekati 0.90-0.91 pada kedua skema evaluasi. Mengingat performa yang hampir setara, pemilihan model akhir dapat didasarkan pada kebutuhan interpretabilitas: jika interpretasi klinis (odds ratio per fitur) menjadi prioritas, Logistic Regression lebih disarankan; namun jika potensi menangkap hubungan non-linear antar fitur klinis menjadi prioritas, Random Forest tetap menjadi pilihan yang kompetitif.

Fitur cp (tipe nyeri dada), thalachh (denyut jantung maksimum), oldpeak (ST depression), thall, exng, dan caa terbukti menjadi prediktor risiko serangan jantung yang paling kuat dan konsisten di seluruh metode feature selection yang digunakan, sehingga dapat menjadi fokus perhatian klinis dalam asesmen risiko pasien.

Penggunaan dua skema evaluasi (repeated holdout dan k-fold CV) serta validasi lintas bahasa (Python dan R) memberikan keyakinan tambahan bahwa hasil yang diperoleh bersifat robust dan tidak bergantung pada satu pembagian data tertentu saja.