EVALUASI AKHIR SEMESTER — DATA MINING

Analisis & Prediksi Risiko Serangan Jantung

Klasifikasi pasien berisiko tinggi vs rendah menggunakan Logistic Regression dan Random Forest

Heart Attack Analysis & Prediction Dataset • 303 Pasien • 13 Fitur Klinis

AGENDA PRESENTASI

01

Problem & Dataset

Latar belakang dan definisi masalah

02

Preprocessing

Pembersihan dan persiapan data

03

EDA & Statistik

Eksplorasi dan visualisasi data

04

Feature Selection

Pemilihan fitur paling informatif

05

Klasifikasi & Evaluasi

Logistic Regression vs Random Forest

06

Kesimpulan

Perbandingan hasil dan rekomendasi

01

Problem & Dataset

LATAR BELAKANG

Mengapa Prediksi Risiko Serangan Jantung Penting?

Rumusan Problem

- Bagaimana karakteristik & pola data klinis yang berhubungan dengan risiko serangan jantung?
- Fitur klinis manakah yang paling informatif untuk prediksi?
- Model klasifikasi mana yang paling akurat dan andal?

Tipe Permasalahan

Binary Classification

Target output: 1 = risiko tinggi, 0 = risiko rendah

164

pasien risiko tinggi (54.3%)

138

pasien risiko rendah (45.7%)

303 total pasien • 302 setelah hapus 1 duplikat • 0 missing value

HEART ATTACK DATASET

Dataset: 13 Fitur Klinis + 1 Target

Fitur	Deskripsi	Fitur	Deskripsi
age	Usia pasien	exng	Angina saat olahraga
sex	Jenis kelamin	oldpeak	ST depression
cp	Tipe nyeri dada	slp	Slope segmen ST
trtbps	Tekanan darah istirahat	caa	Jumlah pembuluh darah
chol	Kolesterol serum	thall	Thalium stress test
fbs	Gula darah puasa	output	Target (risiko tinggi/rendah)
restecg	Hasil EKG istirahat		
thalachh	Denyut jantung maks.		

02

Data Preprocessing

PERSIAPAN DATA

Langkah Preprocessing yang Dilakukan

1

Missing Value Check

0 nilai hilang ditemukan pada seluruh 14 kolom

2

Duplicate Removal

1 baris duplikat dihapus → 302 baris bersih

3

Outlier Detection (IQR)

trtbps (9), chol (5), oldpeak (5), thalachh (1) outlier — dipertahankan (relevan klinis)

4

Feature Scaling

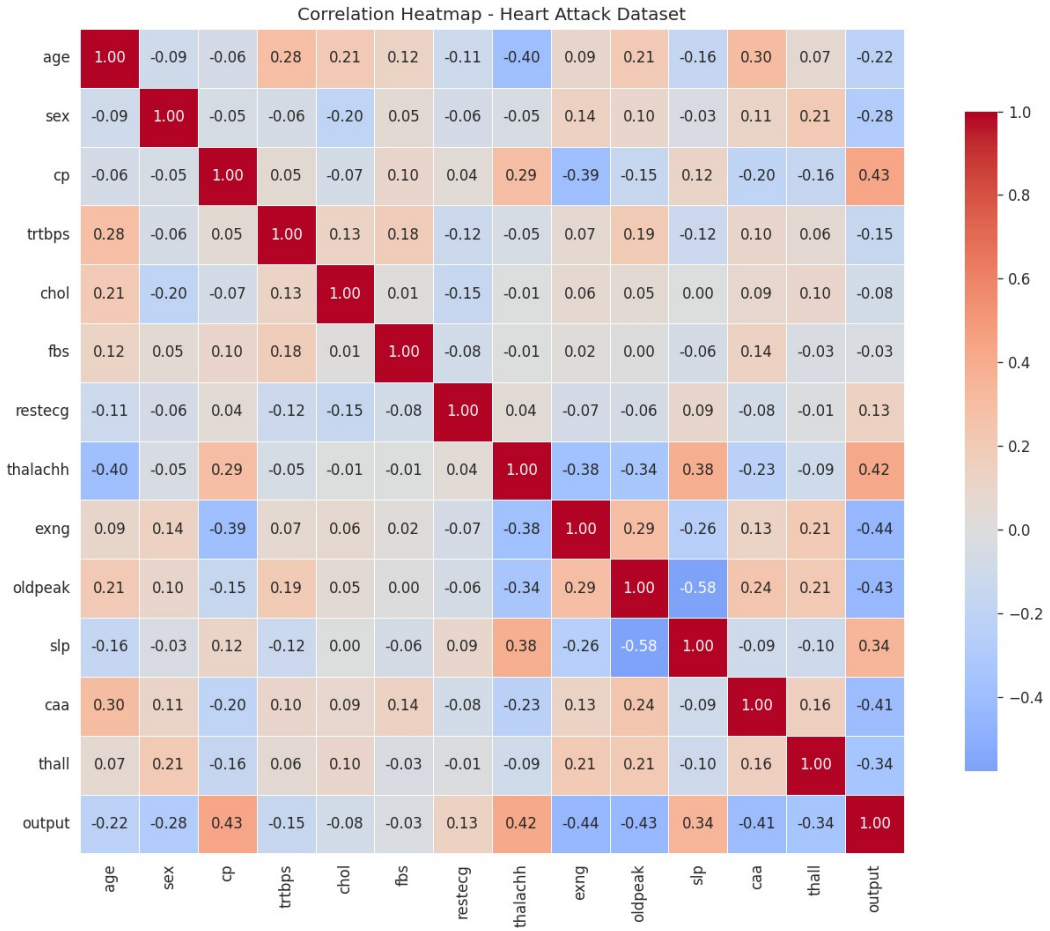
StandardScaler, fit hanya pada data training (cegah data leakage)

03

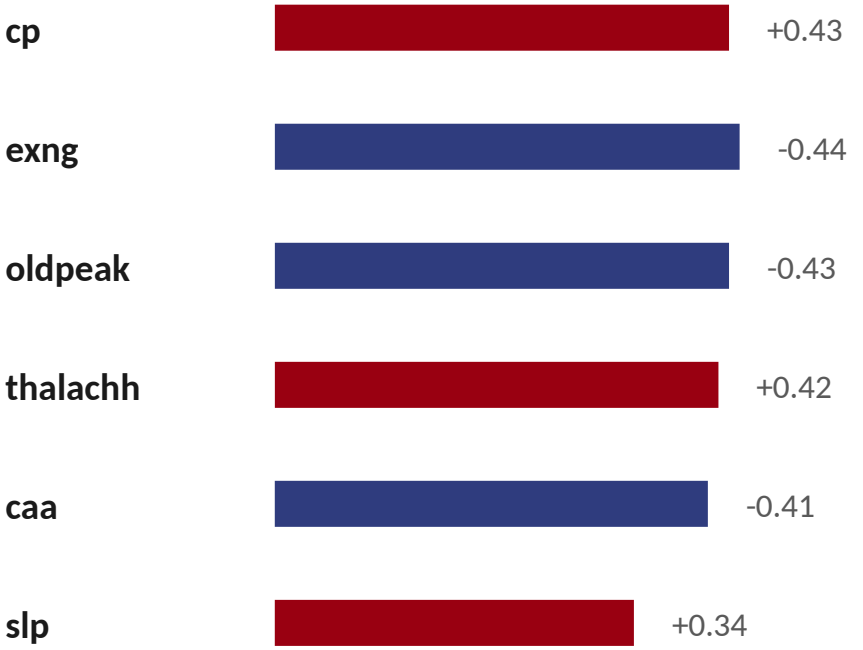
EDA & Statistik

EXPLORATORY DATA ANALYSIS

Korelasi Antar Fitur dengan Target



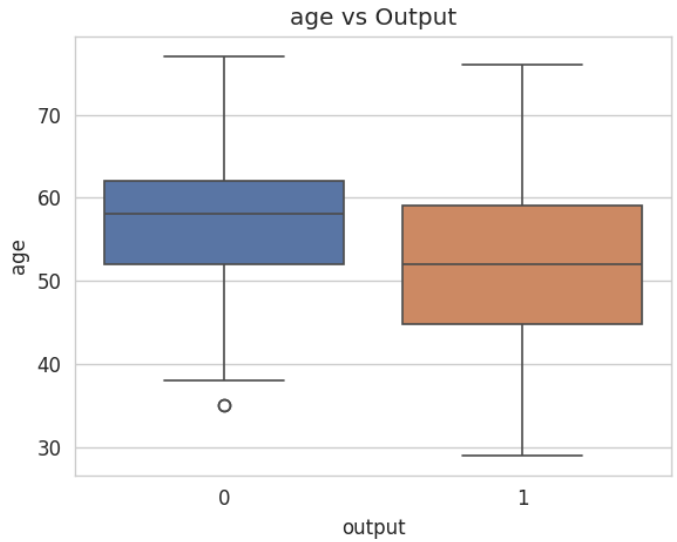
Korelasi Terkuat dengan Output

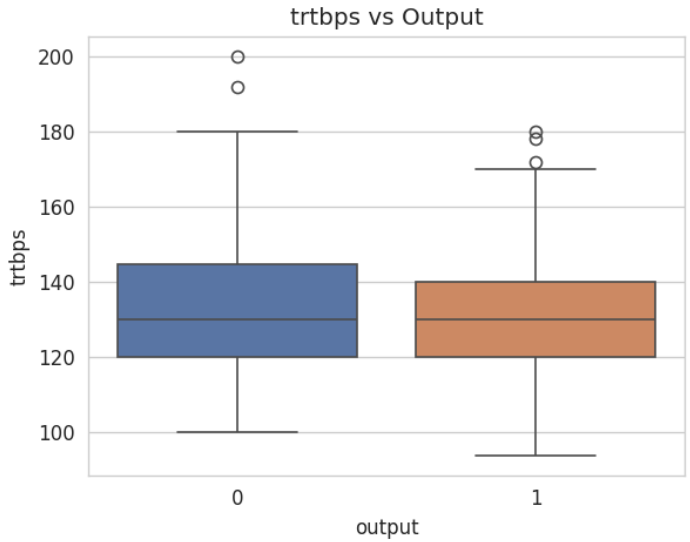


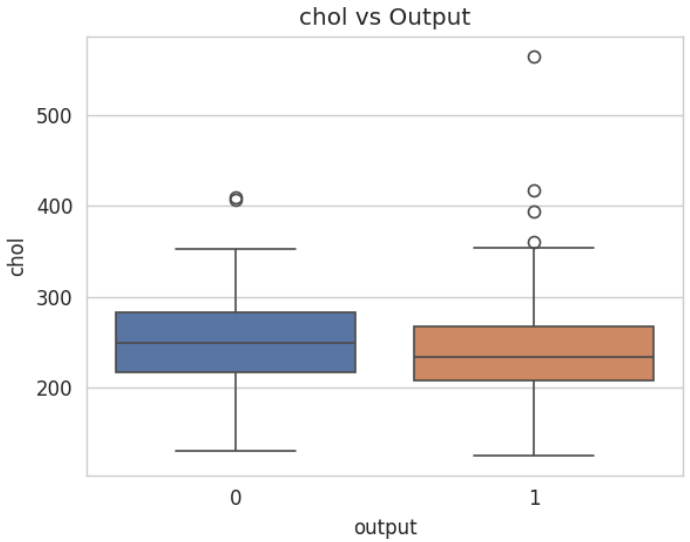
chol dan fbs menunjukkan korelasi sangat lemah (~0) terhadap target

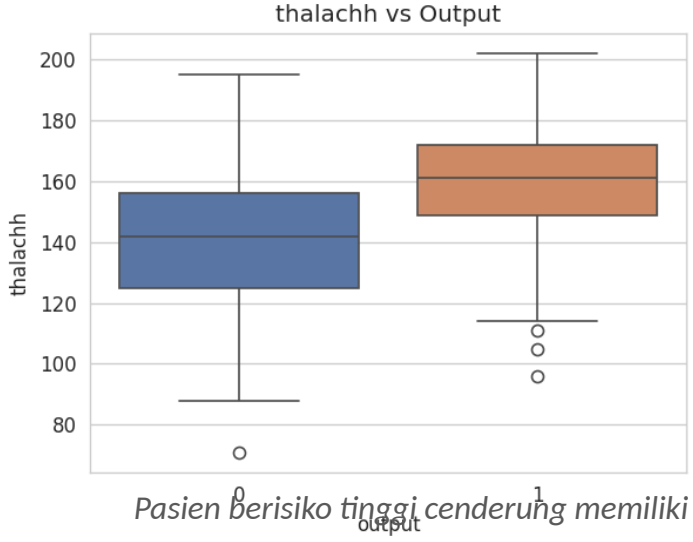
EXPLORATORY DATA ANALYSIS

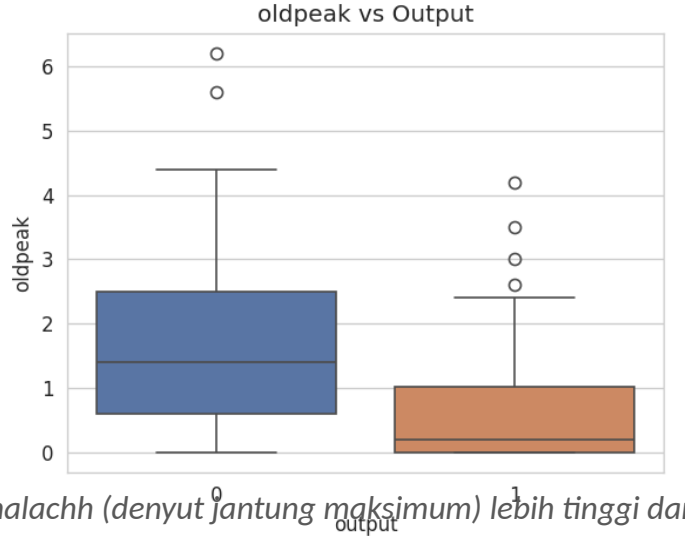
Pola Fitur Numerik Berdasarkan Kelas Target











Pasien berisiko tinggi cenderung memiliki thalachh (denyut jantung maksimum) lebih tinggi dan oldpeak (ST depression) lebih rendah.

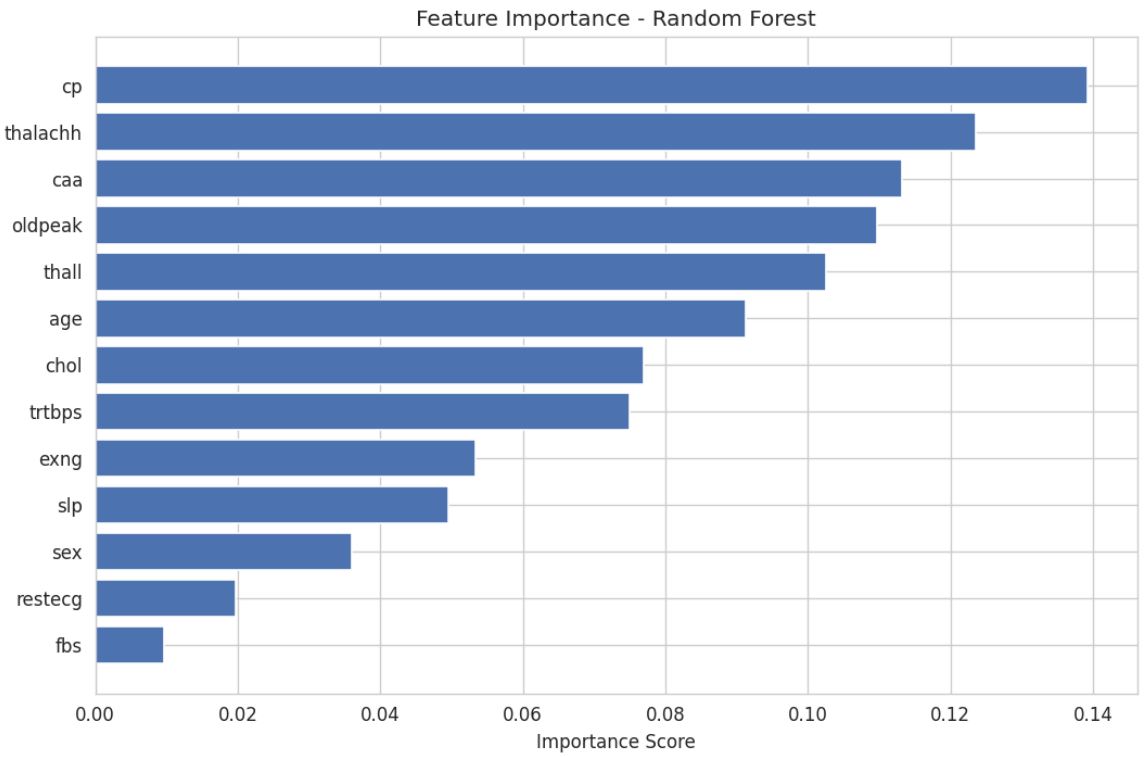
04

Feature Selection

FEATURE SELECTION / EXTRACTION

8 Fitur Paling Informatif

Berdasarkan rata-rata ranking dari 3 metode: ANOVA F-test, Mutual Information, dan Random Forest Importance



#	Fitur	Avg Rank
1	**cp**	1.33
2	**oldpeak**	3.33
3	**thalachh**	4.67
4	**thall**	4.67
5	**exng**	5.33
6	**caa**	5.67
7	**slp**	7.00
8	**chol**	7.67

05

Klasifikasi & Evaluasi

MODEL

Dua Metode Klasifikasi yang Dibandingkan

Logistic Regression

Model linear, mudah diinterpretasi (odds ratio), baseline standar pada literatur prediksi penyakit jantung.

Random Forest

Model ensemble berbasis pohon keputusan, menangkap hubungan non-linear & interaksi antar fitur.

Mengapa kombinasi ini?

Merepresentasikan dua pendekatan yang kontras — linear (interpretable) vs ensemble non-linear (powerful) — sehingga perbandingan hasil informatif untuk menentukan trade-off antara interpretabilitas dan performa.

METODOLOGI EVALUASI

Skema Training-Testing

10x

Repeated Holdout

Split 70:30 (stratified), diulang 10x dengan seed berbeda, hasil dirata-rata.

k=10

K-Fold Cross Validation

Data dibagi 10 fold (stratified), setiap fold bergilir jadi data testing.

Catatan Metodologis

Pada kedua skema, StandardScaler selalu di-fit hanya pada data training di setiap iterasi/fold untuk mencegah data leakage ke data testing. Validasi tambahan juga dilakukan menggunakan bahasa R (package caret, randomForest, pROC).

PERBANDINGAN MODEL

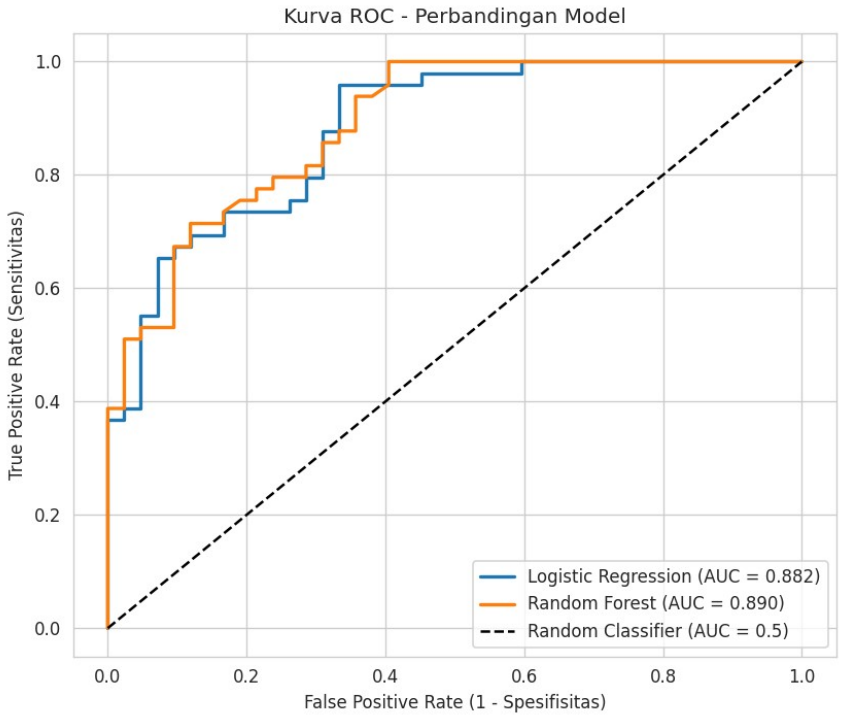
Hasil Evaluasi: Akurasi, Sensitivitas, Spesifisitas, AUC

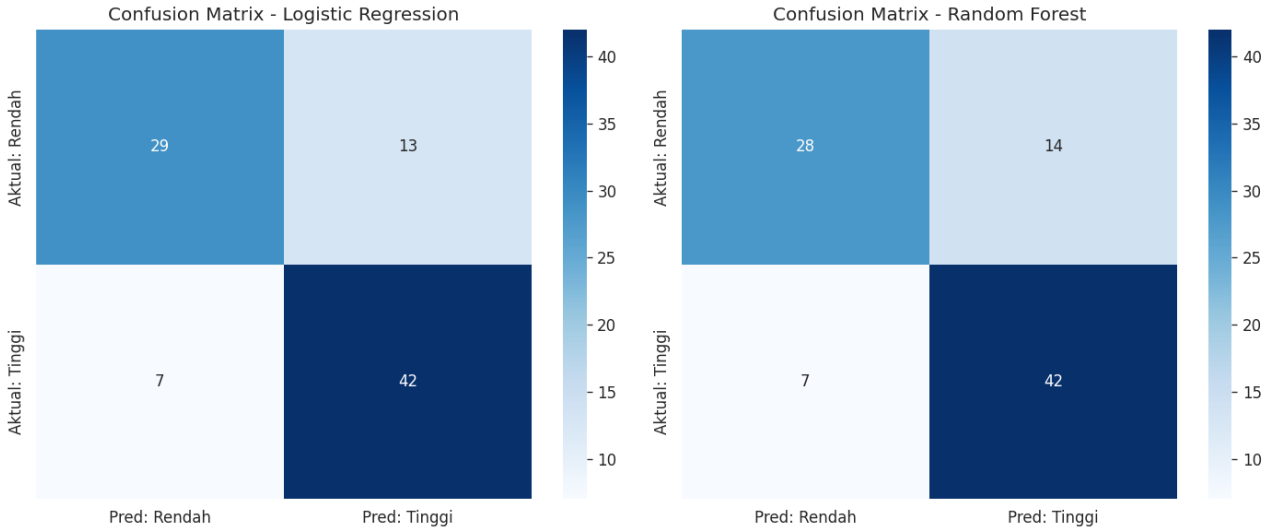
Model	Metode Evaluasi	Akurasi	Sensitivitas	Spesifisitas	AUC
Logistic Regression	Repeated Holdout (10x)	83.96%	88.16%	79.05%	0.908
Random Forest	Repeated Holdout (10x)	82.20%	84.49%	79.52%	0.908
Logistic Regression	10-Fold Cross Validation	83.09%	89.67%	75.38%	0.899
Random Forest	10-Fold Cross Validation	82.42%	87.24%	76.92%	0.900

Kedua model kompetitif: Logistic Regression unggul tipis pada akurasi & sensitivitas; AUC keduanya ≈ 0.90

VISUALISASI PERFORMA MODEL

Kurva ROC dan Confusion Matrix





AUC ≈ 0.88–0.91 — kemampuan diskriminasi sangat baik, jauh di atas classifier acak (AUC=0.5)

06

Kesimpulan

KESIMPULAN

Ringkasan Temuan

1. Logistic Regression sedikit lebih unggul pada akurasi & sensitivitas (≈83-84% vs ≈82%), menunjukkan hubungan fitur-target cenderung mendekati linear.

2. Random Forest sedikit lebih baik pada spesifisitas (79.5% vs 79.0%) di skema Repeated Holdout.

3. AUC kedua model sangat berdekatan dan tinggi (≈0.90) — kemampuan diskriminasi sangat baik.

4. Sensitivitas > spesifisitas pada kedua model — menguntungkan secara klinis (jarang melewatkan pasien berisiko tinggi).

Kesimpulan Akhir

Kedua model menunjukkan performa sangat baik dan kompetitif dalam memprediksi risiko serangan jantung, dengan AUC mendekati 0.90–0.91 pada kedua skema evaluasi.

Prioritas Interpretabilitas Klinis	Logistic Regression — odds ratio mudah dipahami tenaga medis
Prioritas Menangkap Pola Non-linear	Random Forest — kompetitif & robust terhadap interaksi fitur
Fitur Klinis Kunci	cp, thalachh, oldpeak, thall, exng, caa — fokus asesmen risiko pasien

Terima Kasih

Pertanyaan & Diskusi